

FOM

FOM Hochschule für Oekonomie & Management

Hochschulzentrum Bonn

Berufsbegleitender Studiengang Wirtschaftsinformatik

zum

Bachelor of Science (B.Sc.)

6. Semester

Seminararbeit im Modul Anwendungsprojekt zum Thema

**„Analyse der Auswirkung geopolitischer Konflikte auf
Aktienindizes“**

Dozent:	Prof. Dr. Julian Schröter
Name:	Lorenz Chylka, Leonard Reglin, Lukas Nießen, Johannes Solbach
Matrikelnummer:	736986, 740270, 728085, 732936
Abgabedatum:	15.06.2026
Wörter Hausarbeit:	XXX
Wörter Code:	XXX

Inhaltsverzeichnis

Abbildungsverzeichnis	IV
Tabellenverzeichnis	V
Abkürzungsverzeichnis	VII
Literaturverzeichnis	VIII
KI-Hilfsmittelverzeichnis	IX
1 Einleitung	1
2 Projektbeschreibung nach CRISP-DM	2
2.1 Business Understanding	2
2.2 Data Understanding	2
2.2.1 Datenquellen und Umfang	3
2.3 Data Preparation	3
2.4 Modeling	4
2.5 Evaluation	4
2.6 Deployment	4
3 Implementierung der Algorithmen	5
3.1 Lineare Regression	5
3.2 DBSCAN	5
3.3 KNN	5
3.4 K-Means Clustering	5
4 Ergebnisse und Visualisierungen	6
5 Limitationen	7

Abbildungsverzeichnis

Tabellenverzeichnis

1	Genutzte Attribute aus den Konflikt­daten (UCDP GED)	3
2	Genutzte Attribute aus den Index­daten (Kaggle)	3

Codeverzeichnis

Abkürzungsverzeichnis

CRISP-DM	Cross Industry Standard Process for Data Mining
DBSCAN	Density-Based Spatial Clustering of Applications with Noise
KNN	K-Nearest Neighbor Algorithmus
ML	Machine Learning
GPR	Geopolitical Risk Index

Literaturverzeichnis

- Caldara, D. und M. Iacoviello (2022). „Measuring geopolitical risk“. In: *American Economic Review* 112.4, S. 1194–1225.
- Chapman, P., J. Clinton, R. Kerber, T. Khabaza, T. Reinartz, C. Shearer und R. Wirth (2000). *CRISP-DM 1.0: Step-by-step data mining guide*. Techn. Ber. NCR Systems Engineering Copenhagen.
- Wirth, R. und J. Hipp (2000). „CRISP-DM: Towards a standard process model for data mining“. In: *Proceedings of the 4th international conference on the practical applications of knowledge discovery and data mining*. Manchester, S. 29–39.

KI-Hilfsmittelverzeichnis

Nr.	KI-System	Prompt / Einsatzzweck
1	Google Gemini	„Hallo Gemini, ich brauche für mein Anwendungsprojekt eine wissenschaftliche Einleitung. Wir untersuchen, wie geopolitische Krisen Aktienkurse beeinflussen. Kannst du einen Text schreiben, der erklärt, warum das wichtig ist (Stichwort Volatilität und Unsicherheit) und warum wir genau Machine Learning dafür benutzen? Das Ganze soll ca. 250 Wörter haben.“
2	Google Gemini	„Hilf mir mal bitte beim 'Business Understanding' für meine Hausarbeit. Wir nutzen das CRISP-DM Modell und ich muss erklären, was das Ziel unserer Analyse ist. Kannst du mir da Hypothesen formulieren, wie Märkte auf Konflikte reagieren, und den wirtschaftlichen Nutzen für Investoren herausstellen?“
3	Google Gemini	„Ich muss das Kapitel 'Data Understanding' schreiben. Ich habe Aktienmarktdaten von Kaggle und Konflikt-Events von der UCDP. Kannst du beschreiben, was diese Quellen beinhalten und wie wir sie zusammenführen? Integriere bitte auch die Datenschemata-Tabellen, damit man sieht, welche Spalten wir genau nutzen.“

1 Einleitung

Die globale Finanzwelt wird in zunehmendem Maße von unvorhersehbaren geopolitischen Ereignissen geprägt, die oft als „Black Swan“-Ereignisse die Stabilität internationaler Märkte nachhaltig erschüttern können. Geopolitische Risiken, sei es in Form von eskalierenden bewaffneten Konflikten, grenzüberschreitenden terroristischen Anschlägen oder tiefgreifenden diplomatischen Spannungen, induzieren eine signifikante Unsicherheit unter den globalen Marktteilnehmern. Diese Unsicherheit spiegelt sich unmittelbar in einer erhöhten Marktvolatilität, massiven Kapitalumschichtungen und oft abrupten Kurskorrekturen in führenden Leitindizes wider (Caldara und Iacoviello 2022). In einer Zeit, in der Informationen in Echtzeit verarbeitet werden, ist die Fähigkeit, solche Schocks quantitativ zu erfassen, für institutionelle Investoren von existenzieller Bedeutung.

Klassische ökonometrische Modelle stoßen bei der Analyse dieser komplexen Zusammenhänge jedoch häufig an ihre methodischen Grenzen. An dieser Stelle bietet das Machine Learning (ML) innovative Lösungsansätze, um verborgene Strukturen und Korrelationen in hochdimensionalen Datenräumen zu identifizieren, die für herkömmliche statistische Tests unsichtbar bleiben. Im Zentrum dieses Anwendungsprojekts steht daher die Entwicklung eines ML-gestützten Frameworks zur Analyse geopolitischer Marktreaktionen.

Dabei kommen komplementäre Algorithmen zum Einsatz: Die lineare Regression dient der Bestimmung grundlegender Sensitivitäten, während DBSCAN zur Identifikation von Marktphasen und Anomalien genutzt wird. Ergänzend ermöglicht der k-Nearest-Neighbor-Algorithmus (KNN) einen fundierten historischen Vergleich, indem er aktuelle Marktszenarien mit ähnlichen Mustern aus der Vergangenheit in Beziehung setzt. Das Ziel der Arbeit ist die Schaffung einer transparenten Datenpipeline, die die Resilienz globaler Indizes gegenüber geopolitischen Schocks objektiv bewertbar macht und somit einen Beitrag zum modernen Risikomanagement leistet. (in Anlehnung an Google Gemini)

2 Projektbeschreibung nach CRISP-DM

2.1 Business Understanding

Die Phase des Business Understanding bildet das Fundament des Projekts nach dem CRISP-DM-Standardmodell (Wirth und Hipp 2000). In diesem ersten Schritt werden die Projektziele aus einer fachlichen Perspektive definiert. Das primäre Ziel besteht darin, die Sensitivität globaler Finanzmärkte gegenüber geopolitischen Schocks quantitativ zu bewerten.

Die zentrale Forschungsfrage lautet: Inwiefern lassen sich durch die Kombination historischer Konflikt Daten (UCDP) und Marktdaten signifikante Muster der Marktreaktion identifizieren? Daraus leiten sich folgende Hypothesen ab:

- H1: Geopolitische Krisen führen zu signifikanten, aber kurzfristigen Kursrückgängen in Leitindizes wie dem S&P 500 oder DAX.
- H2: Die Resistenz gegenüber Konflikten variiert stark zwischen verschiedenen regionalen Indizes (Geopolitische Resilienz).
- H3: Mithilfe von Clustering-Verfahren lassen sich Marktphasen identifizieren, die eindeutig mit Eskalationsstufen von Konflikten korrelieren.

Der wirtschaftliche Mehrwert liegt in einer verbesserten Risikobewertung für Investoren, um krisenbedingte Marktanomalien frühzeitig zu erkennen. (in Anlehnung an Google Gemini)

2.2 Data Understanding

Die Phase des Data Understanding befasst sich mit der Erhebung, Qualitätsprüfung und strukturellen Einordnung der Daten (Chapman u. a. 2000). Für die vorliegende Analyse werden tägliche Indexdaten mit ereignisbasierten Konflikt Daten auf Kalendertagebene zusammengeführt. Zentrale Prüfpunkte in dieser Phase sind die Datumsabdeckung beider Quellen, fehlende Handelswerte sowie die Präzision der Konflikt Datierung. Für die spätere Modellierung werden nur diejenigen Attribute berücksichtigt, die unmittelbar für das tagesgenaue Matching und die Konstruktion der finalen Analysemerkmale benötigt werden.

2.2.1 Datenquellen und Umfang

Der primäre Datensatz für die Finanzmarktanalyse stammt aus dem Kaggle-Stock-Exchange-Datensatz und enthält historische Tageswerte internationaler Indizes. Als zweite Quelle wird das UCDP GED (Global Event Dataset) verwendet, das konfliktbezogene Einzelergebnisse mit Datums- und Intensitätsangaben bereitstellt. Für die tatsächliche Datenpipeline wurden die in Tabelle 1 und Tabelle 2 aufgeführten Attribute genutzt.

Tabelle 1: Genutzte Attribute aus den Konfliktdaten (UCDP GED)

Spalte	Beschreibung
date_start	Ereignisdatum für das Matching auf Handelstage
date_prec	Datumsqualität; verwendet als Filter (nur Wert 1)
type_of_violence	Konflikttyp zur täglichen Konfliktstruktur
country_id	Anzahl betroffener Länder pro Tag
region	Anzahl betroffener Regionen pro Tag
event_clarity	Qualitätsmerkmal des Ereignisses
where_prec	Präzision der Ortsangabe
number_of_sources	Quellenanzahl als Robustheitsindikator
best	Zentrale Schätzung der Todesopfer (Intensität)
deaths_civilians	Zivile Opfer pro Ereignis

Tabelle 2: Genutzte Attribute aus den Indexdaten (Kaggle)

Spalte	Beschreibung
Index	Eindeutige Indexkennung
Date	Handelstag und Matching-Key
Open	Eröffnungskurs
High	Tageshoch
Low	Tagestief
Close	Schlusskurs
Adj_Close	Bereinigter Schlusskurs
Volume	Handelsvolumen
daily_return	Abgeleitete Tagesrendite
intraday_range	Abgeleitete Tagesvolatilität
volume_change	Abgeleitete Veränderung des Volumens

2.3 Data Preparation

Datenbereinigung, Matching zwischen Konflikt- und Aktienmarktdaten sowie Normalisierung.

2.4 Modeling

Einordnung der in Kapitel 3 beschriebenen Algorithmen in den Workflow.

2.5 Evaluation

Methodik der Modellgüteprüfung (Train-Test-Split, Metriken etc.).

2.6 Deployment

Beschreibung des Projekt-Repositorys und der Reproduzierbarkeit.

3 Implementierung der Algorithmen

3.1 Lineare Regression

3.2 DBSCAN

3.3 KNN

3.4 K-Means Clustering

Das K-Means-Verfahren wurde als exploratives, unüberwachtes Verfahren eingesetzt, um ähnliche Markt-Konflikt-Situationen in der Datenbasis zu segmentieren. Ziel war nicht die kausale Schätzung eines Effekts, sondern die Identifikation von wiederkehrenden Strukturen im Merkmalsraum. Hierfür wurden numerische Merkmale wie tägliche Rendite, Intraday-Range, Konflikttanzahl und Konfliktschwere verwendet.

Vor der Modellierung erfolgte eine Standardisierung aller Features, damit keine einzelne Variable allein aufgrund ihrer Skala die Distanz dominiert. Anschließend wurde K-Means für mehrere Werte von k berechnet. Die Wahl der Clusterzahl erfolgte datengetrieben über den Silhouette-Score. Formal minimiert K-Means die quadratische Distanz der Beobachtungen zu ihren jeweiligen Clusterzentren:

$$\min_{C_1, \dots, C_k} \sum_{j=1}^k \sum_{x_i \in C_j} \|x_i - \mu_j\|^2$$

mit μ_j als Zentrum von Cluster C_j .

Die Ergebnisse wurden über Clusterprofile (Mittelwerte je Cluster) interpretiert. Dabei zeigte sich, dass K-Means insbesondere zwischen konfliktarmen und konfliktreichen Handelstagen differenziert. Dieses Erkenntnis ist für die Hypothesengenerierung hilfreich, ersetzt jedoch keine inferenzstatistische Wirkungsanalyse. Daher wird die kausale bzw. statistisch-signifikante Prüfung des Zusammenhangs in der Arbeit über Event-Study- und Regressionsansätze ergänzt.

4 Ergebnisse und Visualisierungen

5 Limitationen

6 Fazit